

# 基于两种算法对无线信道“指纹”特征识别

**摘要：**本文针对无线信道“指纹”特征建模，包括“指纹”特征参数的建立、匹配识别、连续特征参数的“区域划分”等问题，用无线信道参数的提取算法、BP 神经网络算法和我们建立的微元试探法对模型进行分析求解。

**关键词：**无线信道“指纹”；BP 神经网络；微元试探法；模式识别

## Recognizing the feature of the wireless channel "fingerprint" based on two algorithms

**Abstract:** In this paper, we modeling the feature of the wireless channel "fingerprint", which including the issues like the establishment of the characteristic parameters of " fingerprint ", matching and recognition and "dividing the region" of continuous characteristic parameters. The model solved by the extraction algorithm about wireless channel parameters, BP neural network algorithm and the infinitesimal heuristics proposed by us.

**Key words:** Wireless channel " fingerprint";BP neural network; Infinitesimal heuristics

### 1 背景描述

移动通信产业一直以惊人的速度迅猛发展，已成为带动全球经济发展的主要高科技产业之一，并对人类生活及社会发展产生巨大影响。在移动通信中，发送端和接收端之间通过电磁波来传输信号，我们可以想象两者之间有一些看不见的电磁通路，并把这些电磁通路称为无线信道。无线信道与周围的环境密切相关，不同环境下的无线信道具有一些差异化的特征。如何发现并提取这些特征并将其应用于优化无线网络，是当前一个研究热点。类比人类指纹，我们将上述无线信道的差异化的特征称为无线信道“指纹”。无线信道“指纹”特征建模，就是在先验模型和测试数据的基础上，提取不同场景或不同区域内无线信道的差异化的特征，进而分析归纳出“指纹”的“数学模型”，并给出清晰准确的“数学描述”。

在典型的无线信道中，电磁波的传输不是单一路径的，而是由许多因散射（包括反射和衍射）而形成的路径所构成。由于电磁波沿各条路径的传播距离不同，因此相同发射信号经由各路径到达接收端的时间各不相同，即多径的时延之间有差异。此外，各条路径对相同发射信号造成的影响各不相同，即多径的系数之间有差异。如图 1 所示。

工程上，考虑到多径系数及多径时延的影响，在保证精度的前提下，可以用“离散线性系统”为无线信道建模。需要注意的是，该模型中的信号及多径系数均为复数。理想信道测量可以理解为获取该系统的单位序列响应，即获取单位脉冲“ $\delta(k)$ ”经无线信道传输后被接收到的信号，如下图所示。





图 1 电磁波传输路径



上述理想信道测量的结果用公式表述如下

$$h[k] = \sum_{l=0}^{L-1} h_l \cdot \delta[k - \tau_l],$$

$$\delta[k] = \begin{cases} 0, & k \neq 0 \\ 1, & k = 0 \end{cases}$$

$$k = 0, 1, \dots, K-1, K \geq \max_l \{\tau_l\}$$

其中，“ $k$ ”为离散信号的样点标识，这里假设共有“ $K$ ”个样点；“ $L$ ”是当前时刻的路径总数；“ $h_l$ ”为当前时刻第 $l$ 条路径上的信道系数，通常是复数；“ $\tau_l$ ”为当前时刻第 $l$ 条路径的时延，且已折算成样点数，即延迟了“ $\tau_l$ ”个样点。显然，复信号“ $h[k]$ ”给出了当前时刻的完整信道。需要强调的是，上述各个参数，包括“ $h_l$ ”、“ $\tau_l$ ”和“ $L$ ”都会随着时间变化而变化，即各个参数具有时变性。相应的，“ $h[k]$ ”的功率在信号波长“ $\lambda$ ”的量级上会出现时而加强时而减弱的快速变化，称之为多径衰落或小尺度衰落。同时，快速变化的功率，其平均值也会出现缓慢的变化，这主要是由于周围环境或气象条件的改变而引起的，称之为阴影衰落或大尺度衰落。两种衰落特征如图2所示。




图2 阴影衰落和大尺度衰落

不同时刻的真实信道测量结果及其对应的无线信道分别为：

$$r[k, n] = \sum_{m=0}^{M-1} h[k-m, n] \cdot g[m] + u[k, n]$$

$$k = 0, 1, \dots, K-1, n = 0, 1, \dots, N-1$$

$$h[k, n] = \sum_{l=0}^{L-1} h_l[n] \cdot \delta[k - \tau_l[n]]$$

其中，“ $n$ ”表示测试的样本标识，对应测试时刻，这里假设工有“ $N$ ”个样本；“ $h_l(n)$ ”表示“ $n$ ”时刻第“ $l$ ”条路径上的信道系数，通常是复数；“ $\tau_l(n)$ ”表示“ $n$ ”时刻第“ $l$ ”条路径时延的样点数；“ $u[k, n]$ ”表示“ $n$ ”时刻第“ $k$ ”个测试样本上引入的复高斯白噪声；“ $r[k, n]$ ”表示“ $n$ ”时刻单位脉冲一次经发送滤波器、信道和接收滤波器后的实际接收信号，是 $k, n$ 的二元函数。显然，我们可以从“ $r[k, n]$ ”中获取完整的指纹信道“ $h[k, n]$ ”。为了便于理解，图3给出了不同时刻下无线信道的示意图，同时也给出了样本标识“ $n$ ”和样点标识“ $k$ ”的相互关系。容易发现，不同时刻下多径的条数、时延以及系数值都有可能发生变化。直观上，变化的参数都含有一些场景化的特征，即上述不同参数的变化可能存在一定的规律。

上述理想信道测量的结果“ $h[k]$ ”是无法直接获取的。因为在真是无线通信系统中，为了改善信号的传输质量，通常需要在系统的发射端和接收端，各增加一个滤波器。所有滤波器在真是信道测量中的影响，可以等效的用函数“ $g[k]$ ”来表示。此时信道测量的结果为：

$$r[k] = \sum_{m=0}^{M-1} h[k-m] \cdot g[m], k = 0, 1, \dots, K-1$$

其中，“ $M$ ”为滤波器的长度，即“ $g[k]$ ”的样点数。考虑到信道的时变性以及实测中引入了噪声，




图3 不同时刻下的无线信道

基于上述或更多的参数及特征，一个场景或一定区域内的无线信道可能存在一定的“指纹”。利用所定义的“指纹”，进行场景的分析以及无线网络的优化，具有重要的意义。

从目前看来，无线信道的识别算法主要有以下三类。第一类是谱估计算法，常见的是 Schmidt[1]提出的多重信号分类法（Multiple Signal Classification, MUSIC），它可以对入射波波前数目、到达方向或发射方向、入射波形的强度和互相关提供渐进的无偏估计。然而，由于该算法对于参数空间搜索的计算量和存储量较大，且当入射信号为相干信号时 MUSIC 算法无

效，因此在[2]提出了新的算法可以对相干信号进行方向估计，表现出更高的精度，且能在低信噪比时准确估计入射信号的数目。第二类算法是参数子空间估计法，这类算法最主要的是在[3]中提出的旋转不变技术估计信号参数算法（Estimating Signal Parameters via Rotational Invariance Techniques, ESPRIT），它利用了信号子空间的旋转不变特性，可以用于水平角的准确参数提取。第三类算法是基于最大似然估计算法（Maximum Likelihood Estimation, MLE）而产生的迭代的期望最大算法（Expectation Maximization, EM）[4][5]。它可以实现对时延、水平角、幅度的联合估计。在[6]中，对 EM 算法进行了推广，得到空间交替广义期望最大算法（Space-Alternating Generalized Expectation Maximization, SAGE），SAGE 算法可以同时有时延、离开角、到达角、多普勒频移、幅度等多位参数进行联合估计。这些无线信道参数提取算法已经在高速铁路场景无线信道特征[7]，无线信道带宽参数估计[8]等方面有所应用。

本文的结构如下：第2节，对待研究的内容进行了详细的介绍和分析；第3节，给出了无线信道识别的两种算法，并建立了具体的模型；第4节给出了所研究问题的结论；第5节对所建立的模型进行了简单的评价。

## 2 待研究内容分析

### 2.1 问题一分析

本研究旨在挖掘、提炼和聚合实测信道数据中的各种特征，进而用数学的语言描述“指纹”，并验证其在不同场景或不同地理位置下的适用性。

我们的试验数据中提供了三种场景的真实信道测量结果。基于三种已知场景的测量结果，我们将采用特征提取的方法，对所提供的样本加以分析，并给出无线信道“指纹”的模型。

在理想情况下，要想完美的区分三个场景，信道测量数据应该是越多越好，也就是说在足够还原场景特征信息的前提下，采样的离散数据越多，还原的场景可信度越高。三种场景的真实信道测量结果的形式是  $N \times K$  维的矩阵，类比于图4，红点表示在指纹上的采样点，每个采样点都有自己的二维坐标和值。但是对过多的点进行数据采集是不现实的，既浪费存储空间又影响数据比对效率。所以我们的办法是从较大的采样矩阵中抽取出有限个可以表征矩阵特性的特征参量，作为无线信道“指纹”。从矩阵角度，我们可以用奇异值分解算法[9]得到矩阵的奇异值，不同场景下得到不同结构的信号矩阵对应唯一的奇异值向量，实际上这里的奇异值与无线通信中多重信号分类（Multiple Signal Classification, MUSIC）算法[1]提取的空间方位谱有对应关系；从无线通信的角度，我们可以用无线信道参数萃取算法，包括旋转不变技术估计信号参数 ESPRIT（Estimation of Signal Parameter via Rotational Invariance Techniques）算法[3]提取噪声方差、时延、离开角、到达角、多普勒频移、复振幅等参数。两种特征值抽取算法的性能特点为：矩阵奇异值所对应的 MUSIC 算法是一种高分辨率的高精度的无线信道参数估计算法，ESPRIT 算法在有效性和稳定性方面有突出的表现[7]。

### 2.2 问题二分析

此外试验数据还提供了与“问题1”中某些场景相对应的二个真实信道测量结果。基于“问题一”中所提供的三个场景，以及所建立的“指纹”模型，我们可以识别出此处提供的二个样本分别属于哪个场景。




图4 指纹识别

问题一中我们已经建立的“指纹”模型和“评价指标”，这里判别两个样本属于哪个场景，本质上就是模式识别问题，我们采用 BP 神经网络算法进行模式识别[10]。

### 2.3 问题三分析

另一组试验数据提供了一条连续路段的真实信道测量结果。该结果对应于以 3km/h 的速度步行近 150m 的测试距离。该路段可能包含不同的场景或环境，对应不同的“指纹”特征。基于第一个问题的方法，我们将其进行合理分段，并给出分段的“指纹”分析。理论上，“区域划分”越细，后续做“区域识别”

的精确程度越高，但过细的“区域划分”会在“指纹”特征中引入更多的错误，导致误判概率增大。

由于所给数据是一个连续区域，因此我们基于实际物理常识选取一个“微元”，然后通过类似于试探搜索的方法进行不等距区域划分，同时建立一个最优划分的评判函数，评判划分效果，并给出最优划分结果。

### 2.4 问题四分析

最后一个试验数据提供了二个真实信道测量结果。基于“问题 3”中的“区域划分”和“问题 1”中的“评价指标”，我们首先通过无线信道参数提取算法给出该数据的信道“指纹”，然后利用模式识别算法和我们建立的评判标准进行信道识别。并判断此处提供的二个样本是否采集自“问题 3”中所提供的路段。

我们的问题分析过程图如图 5 所示。

## 3 两种算法和模型建立

### 3.1 基于无线信道参数提取算法的“指纹”模型和“评价指标”

#### 3.1.1 矩阵奇异值分解和旋转不变技术估计信号

矩阵的奇异值分解算法是一种较为简单的算法，这里就不做具体介绍，详细过程可参考文献[9]。一般我们用 MATLAB 工具箱自带的 SVD 函数求解即可。

ESPRIT 算法在有效性和稳定性方面都有非常突出的表现，已经被公认为空间谱估计得一种经典算法。下面我们简单介绍 ESPRIT 算法[3]。

首先，我们把  $K \times N$  的二维矩阵  $r[k, n]$  分解成两个子阵，分别为：

$$r[i, n] = X(n), i = 1, 2, \dots, k-1 \quad r[j, n] = Y(n), i = 2, 3, \dots, k$$

其中这两个子矩阵可以表示为：

$$X(n) = AS(n) + N_x(n)$$

$$Y(n) = A\Phi S(n) + N_y(n)$$

子矩阵 1 接收的信号矩阵为  $X(n)$ ，输出噪声为  $N_x$ ，子矩阵 2 接收的信号矩阵  $Y(n)$ ，输出噪声为  $N_y$ ，它们都为均值为零的高斯白噪声，且相互独立，则满足下式：

$$X(n) = [x_1(n), x_2(n), \dots, x_i(n)]^T$$

$$Y(n) = [y_1(n), y_2(n), \dots, y_j(n)]^T$$

$$S(n) = [s_1(n), s_2(n), \dots, s_{k-1}(n)]^T$$

$$A(n) = [a(\theta_1), a(\theta_2), \dots, a(\theta_{k-1})]^T,$$

$$\theta_p = w_0 \sin \theta_p / c$$

其中



$$\Phi = \text{diag}(e^{jw_1}, e^{jw_2}, \dots, e^{jw_d}),$$

$$w_i = 2\pi d \sin \theta_i / \lambda, w_0 = \frac{2\pi}{T}$$

这里的  $T$  是发射脉冲的周期。由公式可知,  $Y$  相当于时  $X$  经过旋转得到的, 可以将  $\Phi$  称为旋转矩阵。由上可知, 矩阵的自相关矩阵与两个矩阵之间的相关矩阵可以表示为:

$$\begin{aligned} R_{XX} &= EX(n)X^H(n) = AR_{SS}A^H + \sigma^2 I \\ R_{XY} &= EX(n)Y^H(n) = AR_{SS}\Phi^H A^H + \sigma^2 Z \end{aligned}$$

式中  $I$  为单位矩阵,  $Z$  相当于把单位矩阵上对角线的 1 下移, 可以表示为:

$$Z = \begin{bmatrix} 0 & & & 0 \\ 1 & & & \\ & \ddots & & \\ & & \ddots & \\ 0 & & & 1 & 0 \end{bmatrix}$$

$\sigma^2$  可以对  $R_{XX}$  进行特征值分解得出, 所以协方差矩阵:

$$\begin{aligned} C_{XX} &= R_{XX} - \sigma^2 I = AR_{SS}A^H \\ C_{YY} &= R_{YY} - \sigma^2 Z = AR_{SS}\Phi^H A^H \end{aligned}$$

从  $C_{XX}$ 、 $C_{YY}$  特征值分解, 若存在单位圆上的  $d$  个特征值, 则可得出波方向入射角。通过上述分析可以知道, ESPEIT 算法的优点就在于他可以不通过进行复杂的空间搜索来计算来波到达角, 从而减少计算量, 且节省了存储空间, 更便于硬件实现, 且可以得到噪声方差。

### 3.1.3 “指纹”模型和“评价指标”建立

根据上述分析, ESPRIT 算法萃取噪声方差和到达角的步骤可以总结如下:

(1) 首先获取一定的接收端数据采样值  $x(1), x(2), \dots, x(N)$ , 进而可以估计输入信号的自相关矩阵  $R_{XX}(0), R_{XX}(1), \dots, R_{XX}(N)$

(2) 由(1)估计出的自相关函数构造子阵空间, 1 到  $N-1$  为第一个子阵, 2 到  $N$  为第二个子阵, 从而求得  $(N-1) \times (N-1)$  自相关矩阵  $R_{XX}$  和  $(N-1) \times (N-1)$  互相关矩阵  $R_{XY}$ 。

(3) 对自相关矩阵  $R_{XX}$  和互相关矩阵  $R_{XY}$  进行特征值分解, 其中最小特征值为噪声方差  $\sigma^2$  的估计值

(4) 由前边公式计算  $C_{XX} = R_{XX} - \sigma^2 I$  和  $C_{YY} = R_{YY} - \sigma^2 Z$

(5) 对矩阵  $C_{XX}$ 、 $C_{XY}$  作特征值分解, 若存在单位圆上的  $d$  个特征值  $e^{jw_i}$ , 则通过  $w_i = 2\pi d \sin \theta_i / \lambda$  式从而求出估计得到到达角值  $\theta_i$ , 否则, 舍弃到达角参数。

经过上面的步骤我们至少可以得到噪声方差特征参数, 即至少可以提取无线信道“指纹”的一项特征。图 6 为 ESPRIT 算法流程图。

## 3.2 基于 BP 神经网络算法的“场景识别”

### 3.2.1 BP 神经网络算法

神经网络是对人脑或自然神经网络的若干基本特性的抽象, 是一种基于连接假说构造的智能仿生模型, 人们试图通过对它的研究最终揭开人脑的奥秘, 建立起能模拟人脑功能和结构的智能系统, 使计算机

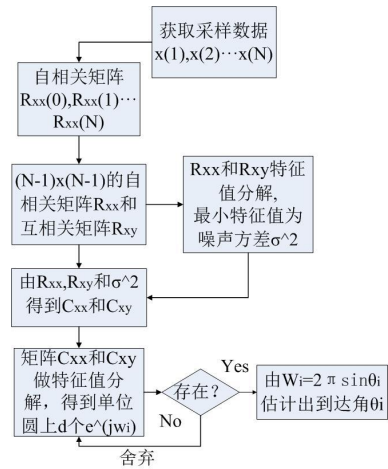


图 6 ESPRIT 算法流程图

能够像人脑那样进行信息处理。本文主要用基于 BP 神经网络算法进行模式识别[10]。

我们以三层 BP 网络为例，介绍该算法。它的结构如图 所示，包含一个输入层、一个隐含层和一个输出层，分别由  $n, p, q$  个神经元组成。BP 神经网络结构如图 8 所示。




图 8 BP 神经网络结构图

该神经网络的隐含神经元的输出为：

$$b_j = f\left(\sum_{i=1}^n w_{ij}x_i - \theta_j\right)$$

输出层神经元的输出为：

$$c_t = f\left(\sum_{j=1}^p v_{jt}b_j - r_t\right)$$

其中， $w_{ij}$  表示输入层第  $i$  个神经元与隐层第  $j$  个神经元之间的连接权； $v_{jt}$  表示隐层第  $j$  个神经元与输出层第  $t$  个神经元之间的连接权； $\theta_j$ 、 $r_t$  表示相应神经元的阈值； $f(x)$  表示神经元的激励函数；这里采用

$$f(x) = \frac{1}{1 + e^{-x}}$$

$y_t$  表示第  $t$  个神经网络的期望输出值； $c_t$  表示第  $t$  个神经网络的实际输出值；当训练样本总数为  $K$  时，网络全局输出误差采用最小方差计算，定义为：

$$\varepsilon = \frac{1}{K} \sum_{k=1}^K \sum_{t=1}^q (y_t - c_t)^2$$

连接权的修正依据反向传播梯度下降法：

(1) 隐含层和输出层神经元之间的连接权  $v_{jt}$  的修正量  $d_t^k$  为

用  $d_t^k$ 、 $b_j$ 、 $v_{jt}$  和  $r_t$  计算下一次的隐含层和输出层之间的新连接权和阈值为：

$$v_{jt}(N) = v_{jt}(N-1) + \alpha \cdot d_t^k \cdot b_j$$

$$r_t(N) = r_t(N-1) + \alpha \cdot d_t^k$$

(2) 输入层到隐含层之间的连接权的修正量  $e_j^k$  为

$$e_j^k = \sum_{t=1}^q (d_t \cdot v_{jt}) \cdot b_j(1 - b_j), (j = 1, 2, \dots, p)$$

用  $e_j^k$ 、 $a_i^k$ 、 $w_{ij}$  和  $\theta_j$  计算下一次输入层和中间层之间新的连接权和阈值为：

$$w_{ij}(N) = \beta \cdot e_j^k \cdot a_i^k + w_{ij}(N-1), (i = 1, 2, \dots, n) \quad \theta_j(N) = \beta \cdot e_j^k + \theta_j(N-1)$$

其中  $\alpha$  和  $\beta$  为学习系数； $N$  为第  $N$  次学习， $x_i^k$  表示输入到网络的第  $k$  个样本， $i$  表示第  $i$  个神经元的输入量， $n$ 、 $p$  和  $q$  分别表示神经网络输入层、中间层和输出层神经元个数。每个样本学习结束，调整相应的连接权值，直到误差函数达到限定值时，判断全局输出误差函数是否到达设定收敛限定值，直到误差函数达到限定值，网络训练结束；否则，如果在达到最大学习次数时误差任然大于设定的数值，训练也结束，网络训练失败。

### 3.2.2 “场景识别”模型建立

利用神经网络进行模式识别的基本步骤是，首先根据待识别模式建立所需神经网络，然后利用待识别模式训练神经网络，最后是测试神经网络。依据 BP 神经网络的基本结构和规则，我们可以在 MATLAB 中编写神经网络进行训练和测试，从而实现图形的识别。

第一步，根据我们基于无线信道参数提取算法的“指纹”模型和“评价指标”，给出信道特征参数向量，即输入模式，形式如下

$X_i = [\text{特征参数1}, \text{特征参数2}, \text{特征参数3}, \dots]$  其中角标  $i$  表示“第  $i$  个场景”。若总共有  $N$  个场景，则  $i = 1, 2, \dots, N$ 。

实际上,我们提取的特征参数是有限的,为了充分利用神经网络,  $X_i$  得元素个数可以用常数补齐,即:  
 $X_i = [\text{特征参数1}, \text{特征参数2}, \text{特征参数3}, \dots, \gamma, \gamma, \dots, \gamma]$  这里常数  $\gamma$  一般取 1 或 0 即可。

考虑到特征参数值的量级有可能相差很大,会给模式识别带来不必要的误差,我们对向量中的特征参量进行同量级化处理,实际上相当于给特征参数换单位,不会影响模式识别的效果。形式如下:

$$X_1 = [\text{特征参数1}/a, \text{特征参数2}/b, \text{特征参数3}/c, \dots, \gamma, \gamma, \dots, \gamma]$$

$$X_2 = [\text{特征参数1}/a, \text{特征参数2}/b, \text{特征参数3}/c, \dots, \gamma, \gamma, \dots, \gamma]$$

...

$$X_N = [\text{特征参数1}/a, \text{特征参数2}/b, \text{特征参数3}/c, \dots, \gamma, \gamma, \dots, \gamma]$$

这里的  $a$ 、 $b$ 、 $c$  根据特征参数的实际取值选取,只要能特征参量同量级化即可。

第二步,根据要识别的“场景个数”确定输出模式的个数。例如,问题一中要识别“场景个数”为 3,则我们可以建立三个输出模式,如下:

$$\text{“场景1” (模式1): } Y1 = [1, 0, 0]^T$$

$$\text{“场景2” (模式2): } Y2 = [0, 1, 0]^T$$

$$\text{“场景3” (模式3): } Y3 = [1, 0, 1]^T$$

当然,如果要识别的“场景”(模式)个数增加的话,我们只需要增加矩阵元素个数即可表示更多的模式。

第三步,确定神经网络的结构参数。例如,我们可以用输入模式和输出模式的个数确定神经网络中输入层、隐含层、输出层的神经元个数。

如果输入向量元素个数为 16,则输入层神经元个数  $n=16$ ,输出模式个数为 3,则输出层神经元个数  $q=3$ ,中间层神经元个数取  $n$ 、 $q$  中间的数即可,这里我们可以取  $p=8$ 。一般情况下,网络的最大容许误差:  $\varepsilon_{\max} = 0.01$ ,学习系数  $\alpha$  和  $\beta$  取 0.01,网络最大学习次数取为 100,该神经网络即可很好的识别不同的模式。最后一步,就是利用建立好的神经网络进行模式识别。整个模式识别建模的步骤流程如图 9。




图9 模式识别流程图

评判误差参数(初始取为 1)。

$$(2) X[i] = f_{\text{提}}(r[k, i]), p = i;$$

$$X[i + p] = f_{\text{提}}(r[k, i + p])$$

$f_{\text{提}}$  为无线信道提取算法提取过程函数

$$(3) \text{ 令 } \mu[c_1] = \frac{|X[i + p] - X[i]|}{|X[i]|}$$

$$(4) \text{ if } (\mu[c_1] > \text{tol}) \quad \text{then}$$

$$R[c_2] = i, c_1 = c_1 + 1, c_2 = c_2 + 1$$

$$\text{if } (\mu[c_1] < \text{tol}) \quad \text{then}$$

$$i = i + p, c_1 = c_1 + 1$$

$$(5) \text{ f}(i \geq n) \quad \text{then} \quad \text{end}$$

else 返回第(2)步,开始内循环

### 3.3 微元试探算法的区域划分实现

#### 3.3.1 微元试探算法

在对题目中第三问进行求解的时候,我们采用了微元试探法进行求解,这个算法是我们自己建立的,只用作该问题的求解。算法如下:

(1) 定义计数器  $c_1 = 1, c_2 = 1$ 、定义误差矩阵  $\mu[c_1]$  和分割点矩阵  $R[c_2]$ 。根据微元假设确定初始步长  $i$ 。 $\text{tol}$  为

(6)待内循环结束后，计算  $g(tol) = \frac{|\mu_{c_1} - tol|}{tol}$ 。

(7)更新  $tol = tol + 0.05$ ，进行外循环，即返回第（2）步。当  $tol > 2.7$ （ $tol > 2.7$  时，已基本不能对区域进行划分），结束外循环。

(8)求  $\arg \max_{tol} \{g(tol)\}$ ，与之对应的  $R[c_2]$  即为最优分割矩阵。

## 4 问题求解

### 4.1 问题一求解

根据我们建立的无线信道特征参数提取算法，包括矩阵奇异值分解算法、旋转不变技术信号参数（ESPIRT）算法，提取每个场景的无线信道特征参数向量。特征参数向量中包括矩阵  $r[k, n]$  的奇异值、噪声方差  $\sigma^2$ 。

首先，为了方便数据包的调用，分别对三个场景中五组数据进行重命名，如下

$$\begin{aligned} [\text{场景}i, \text{第}j\text{组数据}] &\rightarrow \text{"test}ij\text{"} \\ i &= 1, 2, 3; j = 1, 2, 3, 4, 5 \end{aligned}$$

然后，调用程序（从对每个场景的五组数据平均值的矩阵中提取特征参数），生成无线信道特征参数向量（无线信道参数“指纹”）。

结果如下表 1

表 1 矩阵奇异值分解联合 ESPRIT 算法提取结果

	噪声方差	矩阵最小奇异值	矩阵最大奇异值
场景 1	0.0104e-8	0.0015	208.4853
场景 2	0.1210e-8	0.0005	60.5752
场景 3	0.1521e-8	0.0004	21.2173

### 4.2 问题二求解

首先，由矩阵奇异值分解算法联合 ESPIRT 算法进行无线信道参数提取，得到无线信道特征参数向量  $X_i = [\text{特征参数1}, \text{特征参数2}, \text{特征参数3}]$ ，即表 中的数据。根据 4.2.2 “场景识别”模型建立的方法，且为了充分利用神经网络性能， $\gamma$  取 1，补足参数向量元素为 16 个。对特征参数向量同量化处理  $a = 1e-9, b = 1e-3, c = 1e3$ 。

然后，对三个场景进行模式标定，即：

“场景1”（模式1）： $Y1 = [1, 0, 0]^T$

“场景2”（模式2）： $Y2 = [0, 1, 0]^T$

“场景3”（模式3）： $Y3 = [1, 0, 1]^T$

模式 X1 识别结果	模式 X2 识别结果	模式 X3 识别结果	模式 X4 识别结果	模式识别结果
0.9688	0.0353	0.0035	0.9728	1 0 0
0.0562	0.9218	0.0724	0.0474	0 1 0
0.0000	0.0372	0.9594	0.0000	0 0 1
				1 0 0
模式 X1 识别结果	模式 X2 识别结果	模式 X3 识别结果	模式 X5 识别结果	模式识别结果
0.9688	0.0353	0.0035	0.9728	1 0 0
0.0562	0.9218	0.0724	0.0474	0 1 0
0.0000	0.0372	0.9594	0.0000	0 0 1
				0 1 0

图 10 模式识别结果

接着，确定神经网络三个结构层神经元的个数。输入层神经元个数  $n = 16$ ，则输出层神经元个数  $q = 3$ ，中间层神经元个数  $p = 8$ ，其他结构参数取小节（4.2.2 “场景识别”模型建立）中的默认值。下面，把处理后的无线信道特征参数向量  $X_1$ （场景 1） $X_2$ （场景 2）， $X_3$ （场景 3）， $X_4$ （样本 1）， $X_5$ （样本 2）带入程序中进行初始化，运行的结果如图 10 所示。

由图 10 的结果可知，我们用矩阵奇异值分解算法联合 ESPIRT 算法进行无线信道参数提取的参数已经足够精确，可以确保模式正常识别，所以下面对无线信道参数提取我们都采用矩阵奇异值分解算法联



合 ESPIRT 算法进行。模式识别的结果为，样本一的数据属于场景 1，样本二的数据属于场景 2。

### 4.3 问题三求解

基于小节（4.3 微元算法的区域划分实现）的微元试探法，“区域划分”模型建立，及相关参数的设定对该条连续路段的真实信道测量结果进行分析，划分路段区域。首先根据我们的基本假设选取“微元”数据，对数据用矩阵奇异值分解算法联合 ESPIRT 算法进行参数提取。然后用微元试探法进行区域划分。我们得到结果图 11




图 11 微元试探法结果图

最优分割点为 (15, 0.7)，所对应的划分的结果

如表 3 所示

表 3 区域最优分段结果

A1 段/m	A2 段/m	A3 段/m	A4 段/m	A5 段/m	A6 段/m
0-10	10-20	20-28	28-40	40-46	46-52
A7 段/m	A8 段/m	A9 段/m	A10 段/m	A11 段/m	A12 段/m
52-104	104-120	120-122	122-138	138-146	146-150

### 4.4 问题四求解

对两个真实信道的测量结果利用矩阵奇异值分解算法联合 ESPIRT 算法进行参数提取，然后用基于 BP 神经网络算法，或微元试探法给出的评判标准进行模式识别。

两种算法识别的结果都是：最后的试验数据提供的两个真实信道的结果都属于 A9 段，即大致 120-122m 区段。

## 5 模型评价

基于问题，我们建立了无线信道参数“指纹”提取算法和“指纹”评价指标模型。对矩阵奇异值分解算法和 ESPRIT 算法提取的参数进行了分析，这两种算法提取的参数能够很好地区别不同的场景。所以实际操作中，只用矩阵奇异值分解算法联合 ESPRIT 算法提取参数即可。

BP 神经网络算法可以很好的识别场景及样本模式，所以这里采用这种模式识别算法是行之有效的。

我们建立的微元试探法能很好地对连续信道区域进行划分并且模型评价函数也能发挥出很好的评价作用。

### 参考文献：

- [1] Schmidt R O. Multiple Emitter Location and Signal Parameter Estimation[J].Antennas and Propagation, IEEE Transactions on, 1986,34(3):276-280.
- [2] LIN T, ZENG X,SUN H. Improved Algorithm for MUSIC Applied in Coherent Signal Parameter Estimation[C]/Electronics and Optoelectronics(ICEOE),2011 International Conference on.IEEE,2011,2(2):411-414.
- [3] Roy R,Kailath T. ESPRIT-estimation of signal parameters via rotational invariance techniques[J].Acoustics, Speech and Signal Processing, IEEE Transactions on,1989,37(7):984-995.
- [4] Feder M, Weinstein E. Parameter Estimation of Superimposed Signals Using the EM Algorithm[J].Acoustics, Speech and Signal Processing , IEEE Transactions on, 1988,36(4):477-489.
- [5] Silverman B W, Jones M C, Wilson J D, *et al.* A Smoothed EM Approach to Indirect Estimation Problems, with Particular Reference to Stereology and Emission Tomography[J]. Journal of the Royal Statistical Society. Series B(Methodological),1990:271-324.
- [6] Fessler J A, Hero A O. Space-alternating Generalized Expectation-maximization Algorithm[J]. Signal Processing, IEEE Transactions on, 1994,42(10):2664-2677.
- [7] 韩彩. 高速铁路场景无线信道参数萃取方法研究[D].北京, 北京交通大学, 2015.  
HAN C. Research on Wireless Channel Parameter Extraction Under High-speed Railway Scenario[D].Beijing, Beijing Jiaotong University,2015.

---

[8] 高远. 基于 SAGE 算法的宽带信道参数提取方法的应用研究[D].南京, 南京邮电大学, 2012.

GAO Y. Parameter Estimation for Broadband Channel System based on SAGE Algorithm[D]. Nanjing, Nanjing University of Posts and Telecommunications,2012.

[9] 徐树方, 钱江. 矩阵计算六讲[M], 北京, 高等教育出版社, 2011

XU S F, QIAN J, Six Parts of Matrix Calculation[M], Beijing, Higher education press, 2011.

[10] 杨丹等 MATLAB 图像处理实例详解[M], 北京, 清华大学出版社, 2013.

YANG D, *et al.* MATLAB Image Processing Examples[M], Beijing, Tsinghua University press, 2013.